

Reporte Técnico Ejecutivo — Sistema RAG

1. Dominio y tamaño del corpus

- **Dominio:** Legislación inmobiliaria, urbana y notarial del Estado de Yucatán y el Municipio de Mérida. (la idea es que se aborden los 3 poderes)
- **Documentos:** 6 ordenamientos normativos vigentes en 7 documentos en formato Markdown (Leyes de Notariado, Desarrollos Inmobiliarios, Asentamientos Humanos, PLD, Reglamento de Construcciones de Mérida y Código INSEJUPY).
- **Volumen:** ~3,000 fragmentos (*chunks*) indexados.
- **Modelo de embeddings:** `gemini-embedding-001` de Google AI (usado tanto en ingesta como en consulta).

2. Estrategia de partición (Chunking) y justificación

- **Criterio semántico:** Detección de artículos legales mediante expresiones regulares (`Art.`, `Artículo X`) para preservar cada precepto como una unidad jurídica completa.
- **Subdivisión y solape:** Artículos de más de 450 palabras se fragmentan con una ventana de 400 palabras y un solape (*overlap*) de 50 palabras para garantizar continuidad contextual.
- **Breadcrumbs:** Inyección automática de la jerarquía previa (`[Documento] > [Título] > [Capítulo] > [Sección]`) en cada fragmento para conservar su marco legal de validez.

3. Criterio de abstención

- **Nivel 1 (Filtro métrico en FastAPI):** Si la similitud coseno máxima recuperada en ChromaDB es inferior a `0.40`, la API omite la llamada al LLM y responde inmediatamente con abstención.
- **Nivel 2 (Prompt estricto en Gemini):** Se utiliza `gemini-flash-latest` con temperatura 0.1 y la directiva cerrada de responder únicamente con la evidencia. Si el contexto no cubre la pregunta, se abstiene obligatoriamente con la frase: "No tengo evidencia suficiente para responder a esta pregunta." marcando `abstained: true`.
- **4. Responsabilidades: Google AI vs. ChromaDB**
- **Google AI (Embeddings):** Transforma el texto de los artículos y de las preguntas en vectores semánticos.
- **ChromaDB:** Almacena de forma persistente en disco (`./chroma`) los vectores, textos y metadatos, y ejecuta la búsqueda por vecinos más cercanos (k-NN / HNSW con distancia coseno).

- **Google AI (Generación):** Recibe la pregunta junto con los fragmentos recuperados de ChromaDB y redacta la respuesta final en español, anclada estrictamente a la evidencia e incluyendo citas y articulado obligatorio.